Pontificia Universidad Católica de Chile
Facultad de Matemáticas
Departamento de Estadística
Profesor: Eloy Alvarado Narváez
Ayudante: Andrés Díaz
Curso: Tópicos Aplicados en Estadística (EYP3407)
Segundo semestre 2026

Trabajo final: análisis estadístico reproducible

12 de octubre de 2026

1. Propósito y organización

El trabajo consiste en desarrollar y comunicar un análisis estadístico reproducible de un problema real. Cada equipo deberá formular una pregunta precisa, preparar los datos, comparar métodos con un diseño de evaluación adecuado y fundamentar sus conclusiones.

El trabajo se realizará en **11 equipos de cuatro integrantes**, de libre elección. Cada equipo deberá inscribirse en Canvas e indicar **tres casos en orden de preferencia**, entre los descritos en el ANEXO. El profesor asignará un caso distinto a cada equipo, considerando las preferencias recibidas.

Se trabajará exclusivamente con el paquete de datos del caso asignado, respetando la población y la respuesta definidas en su ficha. La preparación de los datos y la construcción de variables deberán realizarse a partir de los archivos entregados, sin incorporar otras fuentes ni sustituir el conjunto de datos.

Aspecto	Condiciones del trabajo
Peso en el curso	30 % de la nota de presentación.
Calificación	Una nota común para los cuatro integrantes.
Componentes	Informe 30 %; repositorio y reproducibilidad 20 %; presentación y defensa 50 %.
Presentaciones	Jueves 12 de noviembre de 2026.
Coevaluación	Confidencial, al finalizar el proyecto; sin ponderación automática.

Qué deberá demostrar el equipo

- Que los predictores utilizados corresponden a la información disponible en el escenario planteado.
- Que la comparación considera selección de modelos, dependencia entre observaciones, incertidumbre y desempeño fuera del ajuste.
- Que otra persona puede reconstruir las tablas, figuras y resultados entregados desde una copia limpia del repositorio.
- Que todos los integrantes comprenden las decisiones centrales y pueden explicarlas en la presentación.

2. Encargo común y construcción de los datos

2.1. Formular el problema antes de ajustar modelos

Antes de ajustar los modelos, el equipo deberá definir a quién está dirigido el análisis y qué decisión podría apoyar. También deberá precisar la población, la unidad de observación, la respuesta y su unidad de medida, el horizonte de predicción y el momento en que estaría disponible cada predictor. Estas definiciones se explicarán en el informe final. Se distinguirá entre predecir un resultado futuro y caracterizar retrospectivamente eventos ya registrados.

Las conclusiones deberán corresponder a la población observada y al objetivo del análisis. Una asociación predictiva no demuestra un efecto causal. Los límites particulares de cada conjunto de datos se detallan en el ANEXO.

2.2. Auditar y construir la base analítica

1. **Documentar la procedencia.** Identificar la institución o proyecto responsable, la versión o fecha de descarga, los archivos originales, los filtros aplicados y las condiciones de uso. Incluir el diccionario de variables y conservar los originales sin editarlos manualmente.

2. **Definir las unidades.** Establecer una clave de fila y comprobar duplicados. Describir relaciones uno a uno, uno a muchos o muchos a muchos antes de unir tablas. Mostrar cuántas filas y unidades independientes hay antes y después de cada unión.

3. **Construir la respuesta.** Explicar códigos, horizontes, denominadores, seguimiento y exclusiones. No asignar automáticamente la categoría negativa a una respuesta desconocida ni imputar respuestas para evaluarlas como observadas.

4. **Auditar predictores.** Entregar una tabla con nombre, interpretación, tipo, disponibilidad temporal y decisión de inclusión. Distinguir identificadores, datos de entrada, resultados posteriores y variables derivadas de la respuesta.

5. **Revisar la calidad de los datos.** Cuantificar valores faltantes, códigos especiales, unidades incompatibles, categorías poco frecuentes y valores imposibles. Distinguir una observación extrema válida de un error de registro. Justificar toda exclusión.

6. **Describir la muestra.** Presentar distribución de la respuesta, cobertura temporal y geográfica, número de entidades, frecuencia de eventos y pérdidas de observaciones. Precisar a quiénes representan los datos disponibles.

2.3. Alcance y carga de trabajo

Cada caso requiere resolver problemas de preparación de datos y de validación. El trabajo se concentrará en esas tareas y en justificar las decisiones tomadas, utilizando el subconjunto entregado.

El tamaño de la base analítica depende de la unidad de observación y del seguimiento requerido. El número de eventos, entidades y periodos importa más que el número bruto de filas. Cualquier reducción adicional de los datos deberá justificarse en el informe y aplicar una regla reproducible que no utilice los resultados de prueba. El tiempo y los recursos destinados al ajuste se adaptarán al tamaño del caso, manteniendo una comparación válida entre métodos.

Cada caso dispone de un archivo `.zip` con los datos, un archivo `LEEME.txt` y los diccionarios necesarios para interpretar las variables. El equipo será responsable de revisar los datos, preparar la base analítica y escribir el código del análisis. Los archivos y los criterios de selección se describen en el ANEXO.

3. Comparación de procedimientos estadísticos

3.1. Modelos mínimos

Cada equipo comparará **una referencia simple y tres procedimientos de aprendizaje**, usando las mismas observaciones de evaluación y la misma información admisible:

Procedimiento	Exigencia
Referencia	Predicción constante, persistencia, patrón estacional o tasa histórica, según el caso. Debe ser una alternativa razonable y calcularse únicamente con datos de entrenamiento.
M1: regresión	Para una respuesta continua: regresión lineal con ridge o lasso. Para una respuesta binaria: regresión logística. Justificar escalas, codificación y selección de variables; en regularización, elegir la penalización mediante validación.
M2: flexibilidad	Para una respuesta continua: árbol podado, splines o GAM. Para una respuesta binaria: árbol podado o SVM de clasificación. Justificar la elección y controlar su complejidad.
M3: ensamble	Bosque aleatorio o boosting, utilizando lo estudiado en el curso y un presupuesto de ajuste razonable.

LDA/QDA pueden añadirse en clasificación, y PCR/PLS en regresión, si responden a una pregunta concreta. La regresión logística penalizada es opcional; no reemplaza la necesidad de justificar su formulación y ajuste. Incluir más modelos no mejora por sí solo la calificación. No se requieren modelos especializados de series de tiempo, supervivencia o estadística espacial, ni redes neuronales o inferencia causal.

3.2. Diseño de la comparación

- Formular antes del ajuste una expectativa sobre cada procedimiento: qué estructura podría capturar y en qué condiciones podría fallar.
- Definir una métrica principal, métricas complementarias y una regla de selección. La métrica principal deberá corresponder al uso del modelo y a la ficha del caso.
- Definir la búsqueda de hiperparámetros, sus límites y el número de evaluaciones. Un punto de partida es un máximo de 20 configuraciones por familia y tres particiones internas válidas. Cualquier ampliación debe justificarse con resultados del conjunto de desarrollo.
- Ajustar transformaciones, imputaciones simples, codificación, selección y modelos usando solamente los datos de entrenamiento de cada partición. Si se utiliza selección de variables, se evalúa el procedimiento completo.
- Comparar, además del error, estabilidad, complejidad, interpretabilidad y costo computacional. Si la ganancia es pequeña o incierta, discutir si justifica la mayor complejidad.

3.3. Profundidad esperada

El informe deberá contener **dos análisis de sensibilidad relevantes**, definidos con los datos de desarrollo. Uno examinará una decisión de preparación o representación de los datos; el otro, una decisión de validación, población o estabilidad. Por ejemplo, se puede estudiar el efecto de transformar la respuesta, excluir una familia de predictores, cambiar una ventana histórica o evaluar grupos y periodos distintos. Cada análisis deberá explicar qué decisión se modifica y cómo cambia la conclusión. Cambiar sólo la presentación de los gráficos no constituye un análisis de sensibilidad.

No es necesario que un método complejo supere a la referencia. Un resultado negativo, correctamente obtenido e interpretado, constituye un resultado válido. Los mecanismos de datos faltantes e imputación múltiple no son exigibles; cualquier tratamiento simple utilizado deberá documentarse y evitar fuga de información.

4. Validación, incertidumbre y análisis de errores

4.1. Separar desarrollo y prueba

Se utilizará un **conjunto de desarrollo** para entrenar, validar y seleccionar modelos, y una **reserva de prueba** para la evaluación final, respetando los periodos de la ficha del caso. Antes de examinar las respuestas de prueba se fijarán la población, las variables, los modelos, las métricas y la regla de selección. Las particiones de desarrollo serán temporales o por entidades, según el objetivo. Una partición aleatoria de filas requiere justificar su adecuación al escenario de uso y la independencia de las observaciones.

En cada partición temporal, **las respuestas de entrenamiento deberán estar disponibles antes del origen de validación**. Se excluirán ventanas cuyo horizonte de respuesta cruce ese origen, respetando los siete días o las 24 horas que corresponden al caso. Los rezagos históricos pueden utilizarse si estaban disponibles al emitir la predicción.

Tras seleccionar el procedimiento en desarrollo, se reajusta con los datos permitidos por el diseño y se evalúa una sola vez en prueba. Se pueden informar los resultados de los modelos definidos previamente, pero no utilizarlos para elegir nuevos hiperparámetros, umbrales o variables. Si se corrige un error de código después de evaluar en prueba, deberán explicarse el error, su corrección y los cambios en los resultados.

4.2. Métricas y unidades

- **Regresión:** informar al menos MAE y RMSE en unidades interpretables. Si se transforma la respuesta, explicar la retransformación y qué cantidad predice el modelo. Evitar MAPE cuando hay ceros o valores próximos a cero. En paneles, acompañar el error global con errores por entidad o una normalización estimada en entrenamiento.
- **Clasificación:** reportar prevalencia, pérdida logarítmica o Brier, AUC ROC y una matriz de confusión para un umbral fijado en desarrollo. La exactitud global no basta ante desbalance: informar también sensibilidad y valor predictivo positivo (VPP). Si se añade el área bajo la curva precisión–sensibilidad, explicar su cálculo.
- **Comparación pareada:** comparar modelos sobre las mismas filas y documentar las exclusiones compartidas. Mostrar una tabla de métricas, la diferencia frente a la referencia y los denominadores de evaluación.

4.3. Incertidumbre y heterogeneidad

Incluir una evaluación de estabilidad o incertidumbre de la diferencia de desempeño entre el modelo elegido y la referencia. Se puede utilizar remuestreo por entidades o bloques temporales, o variación entre ventanas de evaluación, con una justificación de la unidad utilizada. No se interpretará la dispersión de ventanas dependientes como un intervalo de confianza de observaciones independientes.

Si se construyen intervalos por remuestreo, indicar qué se remuestrea, cuántas réplicas se usan y si el modelo se reajusta. Remuestrear pérdidas de una prueba con predicciones fijas describe incertidumbre condicional a los ajustes realizados; no incorpora automáticamente la incertidumbre de selección y entrenamiento.

4.4. Diagnóstico mínimo

Mostrar errores en al menos dos subgrupos o periodos relevantes, con sus tamaños; analizar extremos o eventos raros; identificar una situación en que la recomendación no sea confiable. Importancia de variables y gráficos de efectos deben interpretarse con cautela ante predictores correlacionados y no presentarse como efectos causales.

4.5. Errores que afectan la validez

La fuga de información, el ajuste sobre la prueba, la duplicación de unidades o las exclusiones injustificadas pueden invalidar la comparación y afectar los criterios correspondientes de la rúbrica. El informe deberá explicar los errores detectados, sus correcciones y sus consecuencias para el análisis.

5. Repositorio público y reproducción completa

5.1. Entorno, datos y punto de entrada

Cada equipo entregará un **repositorio público en GitHub o una plataforma equivalente**, accesible mediante el enlace incluido en la entrega. Se permite R o Python. El archivo `README.md` identificará integrantes, caso, versiones del lenguaje y paquetes, instalación y comando de ejecución.

La reproducción debe funcionar desde una copia limpia, sin objetos de una sesión previa, rutas particulares del computador del autor ni cambios manuales en hojas de cálculo. Tras instalar las dependencias y disponer los datos según el `README.md`, **un único comando** ejecutará preparación, particiones, ajuste, evaluación y generación del informe, tablas y figuras. Por ejemplo:

```
Rscript --vanilla analisis.R
# Alternativa si se utiliza Python:
python analisis.py
```

Se documentará el comando que realmente utiliza el equipo. Un notebook debe ejecutarse completo, en orden y desde un proceso nuevo. Se aceptan Quarto, R Markdown u otras herramientas que permitan generar el informe automáticamente.

El repositorio puede contener **un único commit con la entrega final**. Se evaluará su contenido final y la reproducción de los resultados; no se exigirá un historial de desarrollo ni un número mínimo de commits. No se solicitarán, revisarán ni calificarán avances del trabajo.

5.2. Organización mínima

Una organización suficiente es la siguiente; pueden añadirse archivos cuando el análisis lo justifique:

```
README.md             # integrantes, datos, entorno y ejecucion
analisis.R            # o analisis.py; punto de entrada
datos/                # archivos de entrada del caso
informe.qmd           # o una fuente equivalente ejecutable
presentacion.pdf
```

El informe `.pdf` y las figuras se generan al ejecutar el análisis. Si el código crece, puede separarse en unos pocos archivos con nombres claros. No se requiere una jerarquía adicional de carpetas. Las dependencias pueden registrarse en el `README.md` o en un archivo sencillo de versiones.

5.3. Datos y documentación

El `README.md` indicará el nombre del archivo `.zip` utilizado, su fuente y versión, y cómo obtenerlo y descomprimirlo en `datos/`. Se conservará la copia utilizada durante el desarrollo. Los archivos grandes pueden alojarse fuera de Git, mediante un enlace de descarga accesible y documentado que respete las condiciones de reutilización de la fuente. El enlace debe proporcionar los datos requeridos para reproducir el análisis; no basta con remitir a la portada de un portal.

La reproducción comienza con los archivos del paquete asignado. No es necesario volver a descargar datos desde los portales de origen. El código del repositorio deberá generar la base analítica y los resultados a partir de esos archivos; una muestra pequeña o resultados precalculados no reemplazan la ejecución del análisis final.

5.4. Control de ejecución

Fijar semillas donde corresponda y documentar tiempo aproximado, sistema y recursos usados. Conservar en el código las reglas de partición y las predicciones necesarias para calcular las métricas. Registrar en el `README.md` una prueba desde una copia limpia: fecha, comando y resultado. Los aportes del equipo y la declaración de uso de IA pueden consignarse en ese mismo archivo.

6. Entregas, informe y uso de herramientas

6.1. Informe final

Extensión: **10–12 páginas de cuerpo**, sin contar portada, referencias y un anexo técnico de hasta seis páginas. No incluir capturas extensas de código ni listados de resultados sin interpretación. La estructura mínima será:

1. **Resumen ejecutivo:** problema, resultado principal, recomendación y principal limitación, en un máximo de 250 palabras.
2. **Problema y datos:** población, unidad, respuesta, disponibilidad de predictores, procedencia y diagrama de construcción de la muestra.
3. **Diseño de evaluación:** esquema de particiones, información disponible, métricas y referencia. Incluir un diagrama temporal o de entidades.
4. **Métodos:** justificación de los tres procedimientos, preprocesamiento, hiperparámetros y presupuesto de búsqueda.
5. **Resultados:** comparación en desarrollo y prueba claramente separadas, incertidumbre, análisis de errores y dos sensibilidades.
6. **Discusión:** respuesta a la pregunta inicial, límites de generalización, utilidad y condiciones para utilizar el modelo.
7. **Reproducibilidad y contribuciones:** comando, versión del repositorio, entradas, tiempo de ejecución y síntesis de los aportes; declaración de IA y referencias.

Como mínimo deberán aparecer una tabla de construcción de la muestra, una tabla de variables admisibles y excluidas, una tabla comparativa de modelos y una figura de diagnóstico. Cada figura tendrá título, unidades, leyenda y una explicación de su función en el argumento.

6.2. Paquete de entrega en Canvas

Un integrante entregará en Canvas, en representación del equipo: el informe y la presentación en formato `.pdf`, el enlace del repositorio público, una copia `.zip` de la versión final y las instrucciones para acceder a los datos. La copia comprimida deberá contener la versión que produce los resultados del informe, sin credenciales ni archivos temporales. Esta copia identificará la entrega aunque el repositorio cambie posteriormente. La coevaluación se entrega individualmente después de las presentaciones.

6.3. Comprobación de reproducibilidad

El equipo deberá probar la ejecución en un entorno nuevo o en el computador de otro integrante y registrar fecha, comando y resultado. Se evaluarán instalación, lectura de las entradas, ejecución completa, concordancia con el informe y ausencia de pasos manuales. Una ejecución que sólo abre resultados guardados no acredita reproducción. Las diapositivas pueden diagramarse manualmente, pero sus cifras y gráficos deben proceder de los resultados reproducidos.

6.4. Uso de inteligencia artificial y fuentes externas

Se permite apoyo de IA para programación, depuración, búsqueda inicial de explicaciones y revisión de redacción, con declaración de herramienta, fecha, propósito, partes afectadas y comprobaciones realizadas. El equipo es responsable de verificar código, resultados, afirmaciones y referencias; debe poder explicarlos. No se aceptan resultados inventados, referencias inexistentes ni código presentado como validado sin haberlo ejecutado.

La defensa se realizará sin asistencia de IA ni comunicación externa. Se permite colaboración dentro del equipo durante el desarrollo; entre equipos puede discutirse documentación general, pero cada uno debe producir su análisis y reconocer cualquier código externo reutilizado. No se cargarán datos personales, sensibles o confidenciales en servicios externos. La coevaluación permanecerá fuera del repositorio compartido.

7. Presentación, defensa y calendario

7.1. Formato de la presentación

Cada equipo dispondrá de **16 minutos**: 10 minutos de exposición, cuatro de preguntas y dos de transición. La presentación tendrá hasta diez diapositivas principales, más diapositivas de apoyo para responder preguntas. La exposición tendrá cuatro secciones, de aproximadamente dos minutos y medio cada una:

1. Problema, población, datos y construcción de la respuesta.
2. Diseño de validación, información admisible y referencia.
3. Métodos, comparación de resultados y diagnóstico.
4. Sensibilidad, recomendación, límites y reproducibilidad.

Al comenzar se sorteará, sin reemplazo, qué integrante presenta cada sección. Todos deberán preparar la exposición completa. Se considerarán los ajustes de participación que correspondan por los canales del curso.

7.2. Defensa del equipo

El profesor y el ayudante formularán preguntas sobre decisiones metodológicas, interpretación o reproducción. Podrán dirigir inicialmente una pregunta a un integrante y luego permitir que el equipo complemente la respuesta. **La presentación y la defensa tendrán una calificación grupal**; no habrá una nota separada para cada intervención.

La pauta observará el fundamento estadístico de las respuestas, el uso de evidencia concreta y el reconocimiento de límites. Todos deberán estar preparados para explicar las decisiones centrales del análisis, interpretar sus resultados y describir cómo se reproducen.

7.3. Fechas de inscripción y entrega

Fecha	Entrega o actividad
14 de octubre, 23:59	Inscripción del equipo en Canvas, con sus cuatro integrantes y tres casos en orden de preferencia.
15 de octubre	Asignación de un caso distinto a cada equipo por el profesor, considerando las preferencias recibidas.
10 de noviembre, 20:00	Informe, repositorio público, presentación y copia comprimida de la entrega final.
12 de noviembre	Exposición y defensa.
13 de noviembre, 23:59	Coevaluación individual confidencial al cierre.

Las consultas metodológicas deberán realizarse antes de examinar las respuestas de la reserva de prueba.

7.4. Horarios de las presentaciones

Se utilizarán el bloque de cátedra y el bloque de la tarde asignado a la interrogación. El orden se definirá durante la jornada de presentaciones. Todos los equipos deberán estar preparados para presentar desde el inicio y durante ambos bloques.

8. Rúbrica común de evaluación

La calidad se evaluará con los mismos criterios en todos los casos. No se compararán directamente el RMSE o el área bajo una curva de equipos con respuestas y poblaciones distintas. Tampoco se premiará el mayor volumen de datos ni la mayor cantidad de métodos.

Componente	Criterio	Peso	Evidencia esperada
Informe	Problema y base analítica	6 %	Población, respuesta, disponibilidad, procedencia y construcción justificadas.
	Diseño y comparación	10 %	Particiones válidas, preprocesamiento interno y referencia/modelos comparables.
	Resultados y sensibilidad	8 %	Métricas, incertidumbre, heterogeneidad y dos análisis de sensibilidad relevantes.
	Conclusiones y comunicación	6 %	Argumento coherente, límites, figuras y referencias verificables.
Repositorio	Entradas y entorno	6 %	Datos identificados, versiones, dependencias e instrucciones claras.
	Ejecución y concordancia	10 %	Ejecución completa desde copia limpia; resultados consistentes con el informe.
	Claridad y organización	4 %	Código legible, nombres claros y correspondencia entre los cálculos y los resultados.
Presentación	Explicación metodológica	18 %	Justificación precisa de decisiones y comprensión del procedimiento.
	Defensa de resultados	17 %	Respuestas sustentadas, interpretación y reconocimiento de límites.
	Síntesis y evidencia	10 %	Selección de resultados, gráficos legibles y recomendación defendible.
	Coordinación y tiempo	5 %	Participación de los cuatro integrantes, continuidad y respeto del tiempo.
Total		**100 %**	Nota común para el equipo.

8.1. Calificación de cada criterio: escala de 1 a 7

Cada criterio recibirá una nota entre 1.0 y 7.0, con un decimal, según los siguientes rangos de desempeño. La nota dentro de cada rango dependerá del grado de cumplimiento y de la evidencia presentada:

Rango	Descripción del desempeño
6.1–7.0	Excelente: cumple íntegramente el criterio, con evidencia suficiente, decisiones justificadas y análisis riguroso.
5.1–6.0	Bien logrado: cumple lo solicitado, con omisiones menores que no afectan la validez.
4.1–5.0	Adecuado: resuelve los aspectos centrales, con debilidades de profundidad o documentación.
3.1–4.0	Parcial: cumple parte de lo solicitado, pero presenta limitaciones importantes en el análisis o su justificación.
2.1–3.0	Insuficiente: errores u omisiones importantes comprometen la validez o la interpretación.
1.0–2.0	Muy insuficiente: evidencia escasa y deficiencias graves. Si no hay evidencia evaluable, corresponde 1.0.

8.2. Cálculo de la nota del trabajo

Si n_j es la nota de cada criterio y w_j su peso porcentual de la tabla,

$$P = \sum_{j=1}^{11} \frac{w_j}{100}\, n_j = 0.30\, N_{\text{informe}} + 0.20\, N_{\text{repositorio}} + 0.50\, N_{\text{presentación}}.$$

La nota de cada componente es el promedio de sus criterios ponderado por sus pesos relativos. Se redondea únicamente la nota final P a un decimal; su escala es de 1.0 a 7.0. El trabajo tiene un peso de 30 % en la nota de presentación del curso.

9. Coevaluación confidencial al finalizar el trabajo

Después de las presentaciones, cada estudiante evaluará a los otros tres integrantes de su equipo mediante un formulario individual en Canvas. Las respuestas serán confidenciales y deberán reflejar su propia experiencia de trabajo; no se completarán de manera consensuada ni se incluirán en el repositorio.

9.1. Criterios y escala

Para cada compañero, indique con qué frecuencia observó las siguientes conductas:

Criterio	Conducta a evaluar
Cumplimiento	Cumplió las tareas y los plazos acordados.
Aporte al trabajo	Contribuyó a las decisiones, el análisis, la programación, la interpretación o la escritura.
Revisión	Revisó el código o los resultados y ayudó a detectar y corregir errores.
Colaboración	Compartió información, escuchó al equipo y participó en la preparación de la presentación.

Se utilizará una escala de cinco niveles: **1 = Nunca; 2 = Rara vez; 3 = A veces; 4 = Casi siempre; 5 = Siempre**. Si no tiene información suficiente para evaluar un criterio, marque **N/O (No observado)**; esta opción no equivale a una valoración baja.

Además de las valoraciones, describa **un aporte concreto de cada compañero** en una o dos frases. Puede añadir un comentario breve sobre alguna dificultad de colaboración que considere necesario informar.

9.2. Uso de las respuestas

La coevaluación permite reconocer aportes y conocer cómo trabajó el equipo. **No tiene ponderación numérica ni modifica automáticamente la nota grupal**. Todos pueden recibir una valoración alta cuando esta refleje lo ocurrido. No se evaluará la contribución a partir del número de commits o de líneas de código.

El profesor y el ayudante revisarán las respuestas. Si aparecen discrepancias importantes, contrastarán los antecedentes y escucharán a las personas involucradas antes de determinar si corresponde aplicar las reglas del curso. Una valoración baja, por sí sola, no implica una penalización.

ANEXO. Conjuntos de datos y encargos por equipo

Cada ficha identifica el paquete de datos, su procedencia, el subconjunto entregado, la pregunta, las tareas de preparación y el diseño de validación. Los archivos `.zip` contienen los datos, `LEEME.txt` y los diccionarios necesarios. Se conservarán la respuesta y la población asignadas; las exclusiones por calidad deberán justificarse y cuantificarse.

Caso	Fuente	Pregunta central	Dificultad principal
01	`CAMELS-CL`, Chile	Caudal diario con un día de anticipación.	Cuencas heterogéneas, historia y cambios hidrológicos.
02	`EPA AirData`	$PM_{2.5}$ del día siguiente.	Monitores, duplicados, cobertura y extremos.
03	`Open Power System Data`	Demanda eléctrica horaria a 24 horas.	Estacionalidad, zonas horarias y disponibilidad.
04	`Seattle Building Energy Benchmarking`	Intensidad energética anual de edificios.	Panel, reporte tardío y variables derivadas.
05	`BTS On-Time Performance`	Incidencia operativa de un vuelo programado.	Fuga temporal, rutas y categorías.
06	`STATS19`, Gran Bretaña	Gravedad entre colisiones registradas.	Uniones, selección y cambios de medición.
07	`Chicago Food Inspections`	Resultado de una inspección rutinaria.	Historia de locales y selección de inspecciones.
08	`NYC 311`	Solicitud sin cierre a los siete días.	Seguimiento, historial y campos posteriores.
09	`DVF`, Francia	Valor de una compraventa residencial.	Unidad transacción, espacio y asimetría.
10	`HMDA, Colorado`	Rechazo de una solicitud hipotecaria.	Códigos, información posterior y cambios entre años.
11	`NOAA Storm Events`	Daño material entre eventos registrados.	Ceros, colas pesadas, episodios y reporte.

Exigencias comunes

Todos los casos requieren una referencia y tres procedimientos, dos análisis de sensibilidad, una reserva independiente del ajuste, evaluación de incertidumbre y reproducción desde una copia limpia. Cada fuente exige resolver problemas de construcción y validación que forman parte del trabajo. Los tamaños indicados en las fichas corresponden al recorte entregado, antes de las exclusiones y transformaciones que deberá justificar el equipo.

Alcance de las conclusiones

Las fuentes contienen mediciones revisadas, registros administrativos y muestras con cobertura limitada. El informe debe distinguir la fecha del fenómeno, la fecha de registro y la fecha de descarga. Si no existe una versión histórica de disponibilidad, se explicitará que se realiza una evaluación retrospectiva bajo un supuesto de información, sin afirmar rendimiento operativo real.

`caso01`. Caudales diarios en cuencas chilenas

Regresión con estructura temporal y heterogeneidad entre cuencas.

Paquete: `caso01_camels_cl.zip`. 30 cuencas y 6 210 fechas; tablas de caudal, precipitación, temperatura y atributos. Incluye diccionario de atributos y descripción del subconjunto entregado.

Fuente y acceso

`CAMELS-CL`: depósito de datos en PANGAEA, de Alvarez-Garreton y colaboradores. La versión original reúne 516 cuencas, caudales diarios, series meteorológicas y atributos de las cuencas. Consultar también el artículo descriptivo y sus definiciones. Se utiliza esta versión archivada, sin mezclarla con actualizaciones posteriores del portal.

Pregunta y recorte de trabajo

¿Cuánto mejora un modelo estadístico la predicción del caudal del día siguiente frente a mantener el caudal observado hoy? Se utilizan 30 cuencas entre 33 y 40 grados de latitud sur y datos de 2000–2016. Entre las cuencas de esa franja se seleccionaron las de mayor número de días con caudal observado en 2000–2012, con desempate por identificador. La selección utiliza exclusivamente cobertura de desarrollo.

Unidad, respuesta y variables

Una fila será una pareja cuenca–día de origen t; la respuesta será el caudal del día $t+1$, en m^3/s o convertido explícitamente a escorrentía equivalente. Se podrán utilizar caudales hasta t, rezagos y acumulados de precipitación, temperaturas históricas, calendario y atributos físicos estables. Las ventanas móviles serán retrospectivas. Se distinguirá el identificador de cuenca de sus características físicas.

Construcción y riesgos que deben resolverse

Unir series por identificador y fecha; comprobar calendarios, unidades y códigos de ausencia. No rellenar caudales de prueba para evaluarlos como observados. Excluir índices hidrológicos calculados utilizando toda la serie, pues pueden resumir respuestas futuras. Los productos meteorológicos incluyen reconstrucciones y revisiones: se declarará el supuesto de disponibilidad al cierre de t y el carácter retrospectivo del ejercicio, sin atribuirle desempeño operativo en tiempo real.

Validación y referencia

Desarrollo: 2000–2012, con ventanas de origen creciente; reserva: 2013–2016, en las mismas cuencas. Cada ajuste sólo podrá utilizar respuestas ya disponibles. La referencia principal será persistencia, $\widehat{Q}_{t+1} = Q_t$. Una referencia estacional estimada en desarrollo será complementaria. La generalización principal es a días futuros de cuencas conocidas; no se afirmará validación en cuencas sin observaciones.

Resultados específicos exigidos

Reportar MAE y RMSE por cuenca y una agregación que no quede dominada por las cuencas de mayor caudal. Definir cualquier escala de normalización en entrenamiento. Examinar caudales altos y bajos con umbrales de desarrollo. Sensibilidades sugeridas: respuesta original frente a transformada; modelo con y sin atributos físicos. Evaluar estabilidad con bloques temporales que preserven la simultaneidad entre cuencas y discutir sequía, regulación y límites de extrapolación.

`caso02`. Calidad del aire y $PM_{2.5}$

Regresión en un panel de estaciones con mediciones y cobertura irregulares.

Paquete: `caso02_epa_pm25.zip`. 156 425 registros diarios originales de 30 estaciones; inventario de sitios y documentación. Los duplicados por instrumento o estándar se conservan para su auditoría.

Fuente y acceso

`EPA AirData`: archivos diarios y descripción de monitores. Se utilizarán archivos anuales de $PM_{2.5}$, parámetro 88101, y metadatos de sitios. La página oficial ofrece archivos `.zip` y documentación de formatos; sus archivos pueden revisarse, por lo que debe fijarse la copia descargada.

Pregunta y recorte de trabajo

¿Es posible predecir la concentración media diaria de $PM_{2.5}$ del día siguiente con la historia de la estación y el calendario? Se utilizan las 30 estaciones de California con más fechas de medición en 2019–2022, con desempate por códigos geográficos; se incluyen sus registros de 2019–2024. La selección no utiliza concentraciones ni errores de prueba.

Unidad, respuesta y variables

Una fila analítica será una estación–día de origen t y la respuesta será la media del día $t + 1$, en $\mu g/m^3$. Candidatos: concentraciones rezagadas, resúmenes de los siete o treinta días anteriores, día de la semana, mes y atributos del sitio. Se utilizarán únicamente las mediciones y los atributos incluidos en el paquete.

Construcción y riesgos que deben resolverse

La clave de un registro original puede incluir estado, condado, sitio, parámetro, `POC`, duración y estándar. Varias filas no implican varias estaciones independientes. Elegir una combinación coherente de instrumento, duración y estándar; explicar duplicados por norma o dispositivo y no promediar indiscriminadamente resúmenes incompatibles. Un día sin medición no equivale a aire limpio. Los rezagos se calcularán sobre fechas calendario, no sobre la fila anterior disponible.

Quedan excluidos como predictores el AQI, máximos y otras medidas del día objetivo derivadas de su concentración. No usar interpolación que mire hacia el futuro. La publicación y revisión de datos puede ser tardía: la comparación será retrospectiva bajo el supuesto explícito de disponer de las mediciones históricas utilizadas.

Validación y referencia

Desarrollo: 2019–2022; reserva: 2023–2024. Validación por bloques temporales, conservando juntas las estaciones de cada fecha. Referencia: última concentración disponible, acompañada de su antigüedad; comparar también un patrón estacional calculado en entrenamiento. No utilizar observaciones del día objetivo de estaciones vecinas para una predicción emitida el día anterior.

Resultados específicos exigidos

MAE principal y RMSE complementario, errores por estación, estación del año y episodios de concentración alta definidos en desarrollo. Examinar cobertura y número de días efectivamente evaluables. Sensibilidades sugeridas: historia corta frente a larga; tratamiento de mediciones extremas válidas. Analizar estabilidad mediante bloques de fechas comunes y explicar cómo la selección de estaciones condiciona la población representada.

`caso03`. Demanda eléctrica europea a 24 horas

Regresión horaria con estacionalidad y disponibilidad temporal.

Paquete: `caso03_demanda_electrica.zip`. 43 824 horas y tres series de demanda: 131 424 valores observados. Incluye marcas temporales UTC y CET/CEST, descritas en `LEEME.txt`.

Fuente y acceso

`Open Power System Data, Time series`, versión 2020-10-06. El paquete contiene demanda eléctrica y otras series energéticas, con archivo horario. Las cinco columnas entregadas se describen en `LEEME.txt`. La versión cubre 2015 hasta mediados de 2020; el caso utiliza años completos.

Pregunta y recorte de trabajo

¿Cuánto puede mejorarse una predicción estacional de la demanda horaria a 24 horas? Se trabajará con la demanda observada de España, Francia y Alemania en 2015–2019. Las tres series se analizarán conjuntamente, documentando sus diferencias de escala y disponibilidad.

Unidad, respuesta y variables

Una fila será país–hora de emisión t; la respuesta será la demanda en MW de $t + 24$. Se utilizarán demanda conocida hasta t, rezagos, promedios exclusivamente retrospectivos y calendario de la hora objetivo. El país puede ser un predictor categórico. La interpretación es una predicción sucesiva a horizonte fijo; no debe confundirse con emitir simultáneamente todo el día siguiente a una hora de mercado determinada.

Construcción y riesgos que deben resolverse

Transformar las columnas de países a una base larga y conservar el tiempo UTC para ordenar. La columna CET/CEST no representa la hora local de los tres países: documentar la conversión al huso correspondiente. Resolver horas repetidas o ausentes asociadas al horario de verano sin duplicar información. Los predictores se construirán con demanda histórica y calendario; ningún valor observado después del origen de predicción puede utilizarse como entrada.

Validación y referencia

Desarrollo: 2015–2018; reserva: 2019. Usar ventanas de origen creciente y separar entrenamiento de validación de modo que las respuestas a 24 horas del primero ya sean conocidas. Referencias: $\widehat{Y}_{t+24} = Y_t$ y demanda de la misma hora de la semana anterior al objetivo, $Y_{t+24-168}$. La referencia estacional elegida se fija en desarrollo.

Resultados específicos exigidos

MAE y RMSE por país, comparación con la referencia y una métrica agregada normalizada por una escala estimada en entrenamiento. Diagnóstico por hora, día laborable y temporada; examinar error en horas de alta demanda. Sensibilidades sugeridas: codificación lineal o cíclica del calendario; longitud de la historia. La incertidumbre debe conservar la dependencia temporal y la coincidencia de fechas entre países. Se aplicarán los métodos del curso utilizando predictores que representen la estructura temporal.

caso04. Intensidad energética de edificios de Seattle

Regresión con datos anuales repetidos y riesgo de fuga por variables derivadas.

Paquete: `caso04_seattle_edificios.zip`. 34 699 registros edificio–año, correspondientes a 3 823 edificios; diccionario de variables. Incluye los años necesarios para construir antecedentes.

Fuente y acceso

`Seattle Building Energy Benchmarking`, 2015–2024; documentación complementaria en Data and Reports de la ciudad. La base reúne edificios sujetos al programa de reporte energético y contiene características físicas, usos y medidas de consumo.

Pregunta y recorte de trabajo

¿Qué tan bien se puede anticipar la intensidad energética anual de edificios conocidos utilizando atributos e historial previamente reportado? Se utiliza el panel 2015–2024 y se construirán respuestas para 2017–2024. Para respetar el retraso de publicación, el diseño base usará información de años hasta $a-2$ al predecir el año a; no se supondrá automáticamente disponible en enero el reporte completo de $a-1$.

Unidad, respuesta y variables

Una fila será edificio–año objetivo. La clave será `osebuildingid` y `datayear`. Respuesta: `siteeui_kbtu_sf`, en kBtu/pie^2. Candidatos: superficie, antigüedad, pisos, tipo de uso, mezcla de usos, localización agregada e intensidad histórica, respetando la versión temporal disponible. Se distinguirán características del edificio de atributos actualizados retrospectivamente.

Construcción y riesgos que deben resolverse

Auditar identificadores, cambios de nombre, áreas reportadas y ausencias de respuesta. La base incluye campos cuyo valor actual puede describir demoliciones o límites distritales posteriores: no deben tratarse como información histórica sin justificación. Excluir consumo total, consumos por combustible, emisiones, ENERGY STAR y otras medidas del año objetivo que contienen o reflejan su consumo. No reconstruir algebraicamente la respuesta con sus componentes.

El uso de edificios con reporte válido condiciona la población y puede introducir selección. No exigir que un edificio sobreviva o reporte todos los años futuros para incluirlo en desarrollo; documentar altas, bajas y pares año–historia disponibles.

Validación y referencia

Desarrollo: respuestas de 2017–2021; reserva: 2023–2024. Para validar un año a, entrenar sólo con respuestas hasta $a-2$, respetando también el retraso del reporte de las etiquetas. El ajuste final se congela con respuestas hasta 2021; los datos de 2022 sólo podrán servir como antecedentes para predecir 2024. Referencias: EUI de $a-2$ y mediana por tipo estimada en entrenamiento para casos sin historia. Examinar edificios excluidos íntegramente del ajuste como sensibilidad de generalización a entidades nuevas.

Resultados específicos exigidos

MAE principal y RMSE complementario en unidades originales; errores por uso y tamaño; examen del periodo de pandemia y de edificios de consumo extremo. Sensibilidades sugeridas: respuesta original frente a logarítmica y evaluación sin el predictor de consumo histórico. Si se transforma, justificar la retransformación. La incertidumbre debe reconocer observaciones repetidas del mismo edificio y choques comunes a un año.

`caso05`. Incidencias operativas en vuelos programados

Clasificación binaria con variables de disponibilidad desigual.

Paquete: `caso05_bts_vuelos.zip`. 130 940 vuelos de 36 archivos mensuales; diccionario de campos y descripción del subconjunto entregado. Se conservan variables posteriores que deben excluirse de los predictores.

Fuente y acceso

Bureau of Transportation Statistics: `Reporting Carrier On-Time Performance`. La documentación distingue horarios programados y reales, retrasos, cancelaciones y desvíos. Los archivos mensuales se obtienen desde el directorio de descargas de TranStats; el paquete identifica los archivos y meses utilizados.

Pregunta y recorte de trabajo

¿Puede identificarse, con información de programación, un vuelo que terminará cancelado, desviado o con al menos 15 minutos de retraso de llegada? Se utilizan vuelos domésticos con salida desde BOS, JFK y LGA, 2022–2024. El paquete contiene aproximadamente el 10 % de los vuelos: se aplicó una regla determinista a la clave formada por fecha, aerolínea, número, origen y hora programada. La regla se describe en `LEEME.txt` y no utiliza el resultado del vuelo.

Unidad, respuesta y variables

Una fila será un vuelo programado, identificado por fecha, aerolínea, número, origen y hora programada, con auditoría de duplicados. La respuesta será uno si `Cancelled=1`, `Diverted=1` o `ArrDel15=1`; cero cuando el vuelo finalice sin esos eventos y tenga resultado conocido. Casos indeterminados se reportan y no se recodifican automáticamente como cero.

Predictores: origen, destino, aerolínea, distancia, duración y horarios programados, calendario y tasas históricas de ruta o compañía calculadas con información ya disponible. El escenario supone disponible la programación utilizada; el archivo retrospectivo no necesariamente conserva su versión exacta del día anterior.

Construcción y riesgos que deben resolverse

Quedan excluidos horarios reales, retraso de salida, tiempos de rodaje, duración real, causas de retraso, códigos de cancelación y cualquier indicador que define la respuesta. No usar matrícula del avión si no se acredita su disponibilidad en el escenario planteado. La codificación de categorías nuevas y de rutas escasas se aprenderá en entrenamiento. Una tasa histórica de retrasos nunca incluirá el vuelo que se está prediciendo ni resultados todavía no observados.

Validación y referencia

Desarrollo: 2022–2023; reserva: 2024. Utilizar bloques cronológicos comunes a todos los aeropuertos y considerar perturbaciones compartidas por fecha. Referencia: probabilidad constante de incidencia estimada en entrenamiento; una tasa suavizada por ruta puede añadirse. Los umbrales de decisión se fijan en desarrollo.

Resultados específicos exigidos

Pérdida logarítmica principal; discriminación, calibración gráfica y matriz de confusión para un umbral justificado. Presentar resultados por aeropuerto, temporada y tipo de incidencia, sin convertir las tres incidencias en tres proyectos separados. Sensibilidades sugeridas: retirar tasas históricas; examinar rutas no vistas. Analizar diferencias entre modelo útil para clasificación retrospectiva y una herramienta operativa que requeriría archivos históricos de programación.

`caso06`. Gravedad de colisiones viales registradas

Clasificación con relaciones entre tablas y cambios en la medición.

Paquete: `caso06_stats19.zip`. 89 931 colisiones, 164 878 vehículos y 106 604 víctimas, en tablas separadas; diccionario oficial con códigos y definiciones.

Fuente y acceso

Department for Transport: Road safety open data, `STATS19`. Archivos anuales de colisiones, vehículos y víctimas, junto con diccionario y guía de ajustes de gravedad. La fuente cubre colisiones con lesiones en vías públicas de Gran Bretaña notificadas a la policía y registradas en el sistema.

Pregunta y recorte de trabajo

¿Qué características distinguen colisiones graves o fatales dentro de las colisiones registradas? Se utilizan los años 2021–2023 y las fuerzas policiales con códigos 1, 6 y 13 del diccionario oficial. El paquete conserva todas sus colisiones y los vehículos y víctimas vinculados, en tres tablas separadas. Es una clasificación retrospectiva condicionada a que la colisión ocurrió y fue registrada; no estima la probabilidad de accidente de un conductor o tramo vial.

Unidad, respuesta y variables

Una fila será una colisión. Respuesta: gravedad registrada fatal o grave frente a leve, respetando los códigos del diccionario de la versión. Candidatos: tipo y clase de vía, límite de velocidad, condiciones de luz y superficie, intersección, calendario y resúmenes de vehículos involucrados. El archivo de víctimas servirá para auditoría de integridad, sin incorporar sus lesiones como predictores.

Construcción y riesgos que deben resolverse

Agregar vehículos a nivel de colisión antes de unirlos; una unión directa de vehículos y víctimas puede multiplicar artificialmente el número de observaciones. Verificar claves, conteos y categorías especiales. Excluir gravedad de víctimas, número de fallecidos o lesionados graves, ajustes derivados de la gravedad y otros campos que revelan la respuesta. Justificar el uso de información reconstruida después de la colisión según el objetivo retrospectivo.

Los cambios en sistemas de reporte pueden modificar la gravedad observada. Revisar la guía oficial y distinguir etiquetas registradas de valores ajustados; no convertir automáticamente probabilidades ajustadas en clases observadas. Identificar fuerzas y periodos con definiciones comparables.

Validación y referencia

Desarrollo: 2021–2022; reserva: 2023. Particiones temporales y análisis por fuerza o región; cada colisión permanece íntegra en una partición. Referencia: prevalencia de gravedad estimada con entrenamiento. El remuestreo reconocerá agrupaciones geográficas o temporales relevantes y no tratará las filas de vehículos como réplicas independientes.

Resultados específicos exigidos

Pérdida logarítmica, curva precisión–sensibilidad y sensibilidad/especificidad para un umbral fijado. Informar calibración y tamaños por región. Sensibilidades sugeridas: excluir variables reconstruidas tras el evento; restringir el análisis a fuerzas con medición homogénea. Concluir sobre gravedad entre registros disponibles, considerando subregistro y cambios de medición; no atribuir causalidad a la importancia de una variable.

caso07. Inspecciones sanitarias de establecimientos

Clasificación con historia de entidades y selección administrativa.

Paquete: `caso07_chicago_inspecciones.zip`. 104 468 inspecciones, de las cuales 52 675 son de tipo `Canvass`; diccionario. Las otras visitas se conservan como historia potencial.

Fuente y acceso

City of Chicago: `Food Inspections`. La fuente contiene inspecciones desde 2010 y advierte sobre posibles duplicados y un cambio de procedimiento el 1 de julio de 2018. Se utilizará sólo el periodo posterior, con una copia congelada y consulta reproducible.

Pregunta y recorte de trabajo

Entre establecimientos sometidos a una inspección rutinaria, ¿cuáles tienen mayor probabilidad de obtener un resultado `Fail`? Recorte: 2019–2024, inspecciones de tipo `Canvass`, excluyendo reinspecciones y visitas por denuncia del resultado principal. Los registros anteriores al periodo objetivo pueden utilizarse únicamente como historia si están incluidos en el paquete y documentados.

Unidad, respuesta y variables

Una fila será una inspección rutinaria única. Respuesta: `Fail` frente a `Pass` o `Pass w/ Conditions`; otros resultados se cuantificarán y excluirán de esta definición binaria. Candidatos: tipo de establecimiento, calendario, ubicación agregada, tiempo desde una visita previa y antecedentes disponibles antes de la inspección. El nivel de riesgo sólo se usará si se justifica que antecede a la visita; en caso contrario se excluye del modelo principal.

Construcción y riesgos que deben resolverse

Auditar `inspection_id`, licencia, dirección y cambios de nombre para enlazar historia sin fusionar establecimientos distintos. Construir antecedentes ordenando visitas; un resultado previo debe estar disponible antes de la visita objetivo. Excluir `violations` de la inspección actual y cualquier texto que describa sus hallazgos. No usar el resultado presente para seleccionar retrospectivamente la historia.

El conjunto sólo representa establecimientos inspeccionados; la frecuencia de visita puede depender de su riesgo. No interpretar el modelo como una estimación de la seguridad de todos los locales de la ciudad. Estudiar las diferencias entre establecimientos con y sin antecedentes observados.

Validación y referencia

Desarrollo: 2019–2022; reserva: 2023–2024. Ventanas temporales; referencia de probabilidad constante calculada en entrenamiento. La pregunta principal permite utilizar historia de establecimientos conocidos. Una sensibilidad separará establecimientos completos para examinar generalización a locales nuevos, manteniendo la cronología de los antecedentes.

Resultados específicos exigidos

Pérdida logarítmica y calibración; precisión y sensibilidad para un umbral operativo justificado, además de prevalencias y tamaños. Describir errores por tipo de local e historia disponible. Sensibilidades sugeridas: excluir antecedentes de inspección; comparar la definición que agrupa aprobados con condiciones con una evaluación separada de esa categoría. No cambiar la respuesta principal después de observar prueba. La incertidumbre reconocerá inspecciones repetidas del mismo establecimiento.

`caso08`. Plazos de cierre de solicitudes municipales

Clasificación a horizonte fijo con seguimiento y actualizaciones administrativas.

Paquete: `caso08_nyc311.zip`. 170 808 solicitudes; fechas de creación y cierre, atributos y diccionario. Se incluye la descripción del subconjunto entregado.

Fuente y acceso

NYC Open Data: `311 Service Requests from 2020 to Present`. La base se actualiza diariamente y contiene solicitudes dirigidas a agencias municipales. El diccionario y las categorías pueden cambiar; se conservará la consulta y una copia fija de la extracción.

Pregunta y recorte de trabajo

Al ingresar una solicitud, ¿cuál es la probabilidad de que siga sin cierre administrativo al cumplirse siete días? Se utilizan solicitudes de HPD con categoría histórica `PLUMBING`, creadas entre 2021 y 2023. La copia incluye todas las solicitudes recuperadas mediante esa consulta y conserva sus fechas de cierre registradas al descargarla. El cierre administrativo no se interpretará como prueba de resolución material del problema.

Unidad, respuesta y variables

Una fila será una solicitud única. Se construirá $Y = 1$ si no se registra cierre durante las primeras 168 horas desde su creación, y $Y = 0$ si el cierre ocurre dentro de ese plazo. Sólo se incluyen solicitudes con al menos siete días de seguimiento respecto de la extracción. Una fecha de cierre ausente se trata como ausencia de cierre registrado al corte, explicitando que puede existir rezago administrativo. Fechas negativas o inconsistentes requieren auditoría.

Predictores: calendario de ingreso, canal, tipo de localización, detalle de la solicitud y ubicación agregada, cuando se puedan considerar atributos de ingreso. Pueden construirse volúmenes de solicitudes anteriores presentes en el paquete, respetando su disponibilidad. Las direcciones o identificadores se usan para enlazar y agrupar, no para publicar listados de residentes.

Construcción y riesgos que deben resolverse

Excluir `closed_date`, estado final, descripción de resolución, fechas de actualización y duración final como predictores. Un historial de resultados sólo incorpora solicitudes cuyo horizonte de siete días ya terminó. La fuente actual puede contener campos corregidos tras el ingreso: documentar el supuesto de estabilidad de los atributos elegidos. No eliminar solicitudes abiertas para simplificar la respuesta, pues alteraría la población objetivo.

Validación y referencia

Desarrollo: 2021–2022; reserva: 2023. Aplicar una separación de al menos siete días entre el origen de validación y los ingresos usados como entrenamiento, comprobando que las respuestas de entrenamiento ya estén disponibles. Referencia: tasa histórica de solicitudes sin cierre a siete días. No incluir el identificador de solicitud como predictor.

Resultados específicos exigidos

Pérdida logarítmica principal, calibración y desempeño por distrito municipal, mes y canal. Sensibilidades sugeridas: retirar el historial del área; examinar agrupación de solicitudes repetidas por inmueble. La incertidumbre debe reconocer dependencia por inmueble o zona y por periodo. Reportar por separado exclusiones por calidad de fechas y discutir qué se pierde al disponer sólo del estado administrativo revisado.

caso09. Valor de transacciones inmobiliarias en Francia

Regresión con unidad transacción, estructura espacial y respuestas asimétricas.

Paquete: `caso09_dvf_rhone.zip`. 301 891 filas correspondientes a 116 320 transacciones registradas; diccionario y descripción de los archivos. El recorte aún requiere reconstruir la unidad transacción.

Fuente y acceso

`Demandes de valeurs foncières géolocalisées (DVF)`. La fuente oficial documenta compraventas, parcelas, locales, superficies, valor y geolocalización. Se utiliza la edición archivada 2025-12; el identificador de transacción depende de esa edición. Las condiciones de reutilización y atribución se indican en la documentación del paquete.

Pregunta y recorte de trabajo

¿Con qué precisión puede estimarse el valor de una compraventa residencial a partir de las características del inmueble, su localización y el contexto temporal? Se utiliza el departamento 69 (Rhône), años 2021–2023. El paquete conserva todas las filas de ese recorte; el equipo deberá identificar ventas con un único inmueble residencial principal y documentar las exclusiones de transacciones complejas.

Unidad, respuesta y variables

Una fila analítica será una transacción, identificada por `id_mutation` dentro de la edición fijada. Respuesta: `valeur_fonciere` en euros. Candidatos: casa o departamento, superficie construida, número de habitaciones, terreno cuando corresponda, mes y localización. Se podrá modelar el logaritmo del valor, pero se evaluará también en euros y se explicará la retransformación.

Construcción y riesgos que deben resolverse

El valor de una transacción puede repetirse en varias filas de parcelas, locales o disposiciones. No sumar esos valores repetidos ni asignar el precio total a cada inmueble. Auditar la consistencia del valor dentro de la transacción, distinguir dependencias de viviendas principales y documentar cómo se identifican ventas múltiples. Si la estructura no permite separar un inmueble único de forma fiable, se excluye la transacción y se cuantifica la pérdida.

No construir predictores como precio por metro cuadrado usando el valor de la transacción objetivo. Los precios históricos de vecinos sólo pueden emplear ventas anteriores disponibles; la publicación de `DVF` es diferida, por lo que cualquier supuesto de disponibilidad deberá declararse. No enriquecer con información privada de compradores o vendedores ni publicar direcciones innecesarias.

Validación y referencia

Desarrollo: 2021–2022; reserva: 2023. La clave de transacción debe permanecer íntegra. Referencia: mediana de precio por tipo, estimada en entrenamiento, con respaldo global para categorías nuevas. Añadir una sensibilidad espacial por comunas o bloques para examinar cuánto depende la predicción de haber observado el mismo mercado local.

Resultados específicos exigidos

MAE principal y RMSE en euros, errores por tipo y zona, examen de ventas de alto valor y de localizaciones con pocos antecedentes. Sensibilidades sugeridas: escala original frente a logarítmica; retirar agregados históricos del vecindario. La incertidumbre reconocerá dependencia espacial y temporal. Discutir la población resultante de excluir ventas complejas y la diferencia entre predicción de precio y explicación causal de sus determinantes.

caso10. Rechazo de solicitudes hipotecarias en Colorado

Clasificación con códigos especiales, cambios temporales y heterogeneidad entre instituciones.

Paquete: caso10_hmda_colorado.zip. 360 045 solicitudes de 2019–2023 y 100 columnas, correspondientes a 1 076 instituciones. Contiene solicitudes_hmda.csv, diccionario.csv y LEEME.txt.

Fuente y acceso

Home Mortgage Disclosure Act (HMDA): datos públicos de solicitudes hipotecarias, publicados por FFIEC y CFPB. El diccionario oficial documenta códigos y modificaciones para proteger la privacidad. La copia entregada conserva los campos de la fuente y agrega un número de fila de procedencia.

Pregunta y recorte de trabajo

¿Qué tan bien permiten las características financieras y de la vivienda distinguir solicitudes rechazadas de aprobadas en un año posterior? Se utilizan solicitudes de compra en Colorado, con préstamo convencional, primera hipoteca, vivienda principal de una unidad y construcción tradicional; se excluyen hipotecas inversas, líneas de crédito y propósitos comerciales. Se conservan todas las solicitudes con decisión registrada: crédito originado, aprobación no aceptada o rechazo. El análisis no representa solicitudes retiradas ni expedientes incompletos.

Unidad, respuesta y variables

Una fila corresponde a una solicitud; la clave técnica combina activity_year y fila_fuente. Respuesta uno si action_taken=3; cero si vale 1 o 2. Candidatos: ingreso, monto solicitado, valor de la vivienda, plazo, razón préstamo–valor, razón deuda–ingreso y condado. lei identifica la institución y permite estudiar heterogeneidad. El objetivo es clasificar decisiones registradas usando atributos del expediente: no estimar incumplimiento del pago ni atribuir un efecto causal a una característica.

Construcción y riesgos que deben resolverse

Interpretar códigos, intervalos, redondeos y valores Exempt o NA; no convertirlos en cero. El ingreso está en miles de dólares, mientras que los montos del préstamo y de la propiedad están en dólares. La razón deuda–ingreso mezcla valores e intervalos. Coincidencias entre atributos públicos no demuestran duplicación de solicitudes; la clave de procedencia no es un predictor ni permite seguir personas.

Excluir como predictores la decisión, sus motivos, el comprador del crédito, tasas y costos del préstamo, y resultados de sistemas automatizados de evaluación. Son campos asociados al proceso o al resultado que pueden revelar la respuesta. Revisar la disponibilidad de los demás campos; el archivo contiene valores finales revisados y no permite reconstruir exactamente lo conocido al ingresar una solicitud. La comparación será retrospectiva, sin presentarla como evaluación operativa en tiempo real.

Validación y referencia

Desarrollo: 2019–2022; reserva: 2023. Validar en 2020, 2021 y 2022 utilizando en cada ajuste sólo años anteriores. No hay fechas que permitan particiones dentro de un año. Referencia: proporción de rechazos en entrenamiento. Hay 16 156 rechazos entre 310 131 solicitudes de desarrollo y 2 829 entre 49 914 de reserva; conservar esas proporciones al evaluar y resolver categorías e instituciones nuevas sin consultar sus respuestas.

Resultados específicos exigidos

Pérdida logarítmica principal; Brier, AUC ROC, calibración, sensibilidad y VPP con umbral fijado en desarrollo. Examinar desempeño por año e institución, informando tamaños y eventos por grupo. Sensibilidades sugeridas: codificación de deuda–ingreso; inclusión o exclusión de la institución. Considerar dependencia por institución al cuantificar incertidumbre y discutir cambios temporales. La logística, los árboles y los ensambles permiten abordar el caso sin exigir modelos de riesgo crediticio especializados.

`caso11`. Daños materiales en eventos meteorológicos

Regresión con ceros, colas pesadas y registros agrupados por episodio.

Paquete: `caso11_noaa_tormentas.zip`. 26 519 eventos agrupados en 3 490 episodios; tabla de detalles y diccionario oficial del formato `.csv`.

Fuente y acceso

`NOAA Storm Events`: archivos anuales comprimidos. Consultar el diccionario oficial del formato `.csv`. Se utilizará únicamente la tabla de detalles incluida en el paquete.

Pregunta y recorte de trabajo

Entre episodios registrados de granizo o viento de tormenta, ¿qué tan bien pueden las características físicas del evento describir el daño material informado? Se utilizan registros `Hail` y `Thunderstorm Wind`, 2018–2023, en Texas, Oklahoma y Kansas. El objetivo es **retrospectivo**: se conocen las características físicas reconstruidas del evento y se estudia daño reportado. No se presenta como pronóstico de daños antes de una tormenta.

Unidad, respuesta y variables

Una fila será un evento, identificado por `EVENT_ID`; varios eventos pueden pertenecer al mismo `EPISODE_ID`. Respuesta: `DAMAGE_PROPERTY`, convertida a dólares nominales. Candidatos: tipo, magnitud física y unidad, duración, mes, localización y características del registro que no codifiquen daños. El tipo de medición de magnitud permitirá distinguir mediciones de estimaciones cuando esté disponible.

Construcción y riesgos que deben resolverse

Interpretar sufijos K, M y B usando el diccionario; distinguir un cero informado de un valor ausente. Verificar magnitudes en unidades distintas: tamaño de granizo y velocidad del viento no forman una escala común. Excluir narrativas que mencionen pérdidas, daños a cultivos, muertes, lesiones y campos derivados de consecuencias. El análisis se limita a los dos tipos de evento incluidos en el paquete.

Los daños son estimaciones informadas y la cobertura depende de mecanismos de reporte. Mantener ceros observados y extremos válidos; explicar exclusiones. El modelo describe registros de eventos, no el riesgo económico de cualquier población. No se exige convertir a moneda constante; al trabajar en dólares nominales debe discutirse la comparabilidad temporal.

Validación y referencia

Desarrollo: 2018–2021; reserva: 2022–2023. Mantener juntos los eventos de un episodio; resolver explícitamente episodios que crucen límites temporales. Referencia: mediana de daño en entrenamiento, complementada con una referencia por tipo. El caso puede modelarse con los métodos de regresión del curso; un modelo en dos partes es una extensión opcional.

Resultados específicos exigidos

MAE en dólares como métrica principal y RMSE complementario; diagnóstico separado para ceros, daños positivos y extremos. Informar cuánto concentran los mayores eventos del error total. Sensibilidades sugeridas: respuesta original frente a $\log(1 + Y)$, explicando la retransformación; evaluación por tipo y magnitud medida/estimada. La incertidumbre se calculará preservando episodios y se discutirá su dependencia geográfica y temporal.